

سوال ۱:

(آ) زمانی که generator عملکرد خوبی نداشته باشد و discriminator بتواند به خوبی داده‌های واقعی را از داده‌های ساخته شده تشخیص دهد، مقدار $(D(G(z)))$ به یک نزدیک میشود و مقدار $\log(1-D(G(z)))$ به منفی بینهایت نزدیک میشود. که در بهینه کردن سیستم مشکلاتی به وجود می آورد. (این مشکل را گرادیان اشباع میگویند.) به همین علت تابع $-\log(D(G(z)))$ را جایگزین $\log(1-D(G(z)))$ میکنند. (پس $-\log(D(G(z)))$ تابع تابع مطلوب تر است.)

(ب) زمانی که GAN به خوبی آموزش داده میشود خواهیم داشت $P_g = P_{data}$ و discriminator بهینه به شکل زیر خواهد بود:

$$D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

پس $D(G(z)) = \frac{1}{2}$ خواهد شد. جمله ذکر شده غلط است.

Theorem (Optimality of GAN)

For G fixed, the optimal discriminator D is

$$D^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

Theorem (Convergence of training algorithm of GAN)

If G and D have enough capacity, and at each step of training Algorithm, the discriminator is allowed to reach its optimum given G , and p_g is updated so as to improve the criterion $V(D, G)$, then, p_g converges to p_{data}

سوال ۲:

هنگامی که generator تنها یک خروجی و یا یک مجموعه خروجی محدود را تولید می کند بهترین رویکرد برای discriminator آن است که همیشه این خروجی های شناخته شده را به عنوان خروجی های غیر واقعی رد کند. حال اگر discriminator نتواند این این خروجی های محدود توسط generator را تشخیص دهد (در یک بهینه محلی گیر کند) پس generator همیشه میتواند با همان خروجی های محدود discriminator را گول بزند و discriminator نمیتواند از این تله خارج شود. به این حالت mode collapse میگویند.

سوال ۳:

یکی از محدودیت های اصلی AE ها تولید نمونه جدید است. زیرا فضای latent در AE ها یک فضای ناپیوسته و بدون ساختار است. به همین دلیل نمیتوان به راحتی نمونه ای را خارج از نمونه های اولیه از فضای latent بازسازی کرد. VAE با داشتن فضای latent ساختارمند قابلیت تولید یک نمونه جدید را فراهم میکند.

سوال ۴:

یکی از مشکلات VAE ها در backpropagation است. زیرا نمونه برداری در فضای latent یک عملیات غیر مشتق پذیر است. پس نمونه Z به گونه پارامترسازی میکنیم تا امکان backpropagation وجود داشته باشد.

1. Autoencoders are simple to train since you simply have to backpropagate the reconstruction loss across the weights of the network.
2. VAEs are not as simple to optimize though.
3. The key problem is that the sampling operation is not differentiable.
4. This means we cannot propagate the gradients from the reconstruction error to the encoder.
5. Normally we would have to resort to more complicated optimization techniques like REINFORCE.

1. We are able to resolve this problem through the reparameterization trick.
2. The idea behind this trick is to isolate the sampling from the parameter estimation (mean and variance).
3. First, we sample ϵ from a unit Gaussian distribution.
4. We can make the sample to adhere to a Gaussian distribution with mean μ and covariance matrix Σ by transforming it.

1. We can generate through Reparametrized VAE as

